LAPORAN PROYEK APLIKASI WEBSITE

KELOMPOK 2

Topik: Analisis Data Percakapan Pengguna X tentang Gaji dan Tantangan Gen Z dalam Memasuki Dunia Kerja

Dosen Pengampu: Akhsin Nurlayli, S.Pd., M.Eng.

Nama Anggota :

1. NESHIA SEPTIARIFA (24051130001)
2. ANGGER SEKARAYU LANGGENG B (24051130003)
3. BAYU ARYA WIJAYA (24051130010)
4. AUDI ARIZ Q (24051130016)

TEKNOLOGI INFORMASI

DEPARTEMEN PENDIDIKAN TEKNIK ELEKTRONIKA DAN INFORMATIKA

FAKULTAS TEKNIK

UNIVERSITAS NEGERI YOGYAKARTA

2026

A. Topik, Kata Kunci, Sumber, Periode, Serta Jumlah Data.

Topik : Gaji, upah minimum regional (UMR), pencarian kerja, dan tantangan memasuki dunia kerja
Kata Kunci : "gaji UMR", "lowongan kerja", dan "fresh graduate"
Sumber : Platform X (Twitter)
Periode : 1 Januari 2026 - 10 Oktober 2026
Data awal : 650
Data akhir : 516

B. Pembersihan Data dan Metode

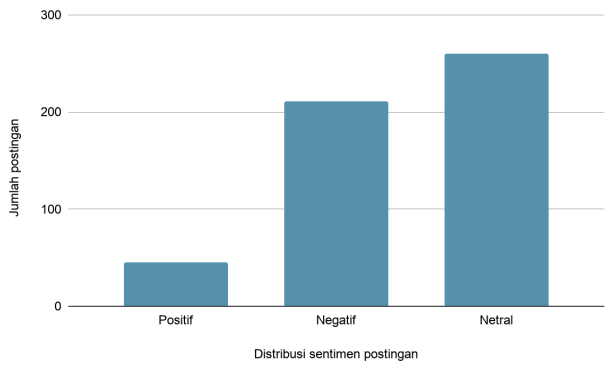
Pengumpulan data dilakukan menggunakan Tweet-Harvest melalui Google Colab dengan kata kunci gabungan “gaji UMR”, “lowongan kerja”, dan “fresh graduate” pada platform X dalam rentang waktu dari 1 Januari 2026 hingga 10 Oktober 2026. Pengambilan data dilakukan sebanyak dua kali dengan batas masing-masing 1.000 dan 500 unggahan. Data yang diperoleh kemudian digabungkan dan melalui tahapan pembersihan sebagai berikut:

1. Penghapusan data duplikat, dengan menggabungkan hasil crawling dari dua file CSV dan menghapus unggahan yang memiliki ID atau isi teks yang sama untuk menghindari penghitungan data berulang.
2. Penghapusan data kosong dan pembersihan teks, dengan membersihkan teks unggahan melalui proses case folding, penghapusan URL, mention, hashtag, simbol, angka, stopwords, serta spasi berlebih. Hasil pembersihan disimpan dalam kolom Cleaned_Text.
3. Normalisasi data, dengan mengonversi tanggal unggahan ke format waktu UTC serta memastikan nilai metrik interaksi, seperti likes, retweet, reply, dan quote, memiliki nilai numerik dengan nilai kosong diisi nol.
4. Penyaringan bahasa dan seleksi relevansi, dengan mempertahankan unggahan berbahasa Indonesia berdasarkan kolom lang, kemudian menyeleksi unggahan yang relevan dengan topik gaji dan tantangan Gen Z dalam memasuki dunia kerja menggunakan daftar kata kunci terkait dunia kerja.
5. Penyimpanan hasil cleaning, dengan menyimpan data yang telah dibersihkan dan diseleksi ke dalam file cleaning_kerja_relevan.csv untuk digunakan pada tahap analisis selanjutnya.

C. Hasil Utama Sentimen, Clustering, dan Regresi.

1. Sentimen

Analisis sentimen terhadap 516 postingan menggunakan model IndoBERT menunjukkan bahwa sentimen netral mendominasi dengan 260 postingan (50,39%), diikuti sentimen negatif sebanyak 211 postingan (40,89%), dan sentimen positif sebanyak 45 postingan (8,72%).



Dominasi sentimen netral menandakan bahwa sebagian besar postingan bersifat informatif, seperti informasi lowongan kerja atau pertanyaan seputar upah, sedangkan sentimen negatif yang mencapai hampir 41% mencerminkan adanya keluhan publik terhadap besaran upah dan

kondisi dunia kerja. Sentimen positif hanya menempati porsi terkecil, sehingga apresiasi terhadap topik ini relatif jarang muncul.

Untuk mengukur kinerja model, hasil prediksi IndoBERT dibandingkan dengan pelabelan manual pada 20 sampel postingan.

Metrik Evaluasi	Jumlah Data	Persentase	Keterangan
Sesuai (Match)	16	80,0%	Prediksi sistem sama dengan label manual
Tidak Sesuai (Mismatch)	4	20,0%	Prediksi sistem berbeda dari label manual
Tidak Sesuai (Mismatch)	20	100,0%	Total data yang diuji pada file evaluasi

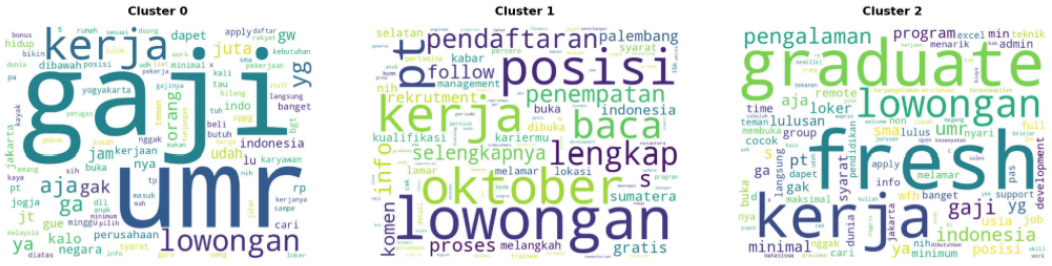
Hasilnya, 16 dari 20 postingan (80,0%) memiliki label yang sesuai, sedangkan 4 postingan (20,0%) tidak sesuai. Ketidaksesuaian umumnya terjadi pada kelas yang berdekatan, yaitu antara netral dengan positif atau negatif, karena batas antara teks netral dan teks beremosi ringan cukup samar, terutama pada bahasa media sosial yang informal dan penuh singkatan. Dengan demikian, IndoBERT dinilai cukup baik dalam mengklasifikasikan sentimen dengan tingkat kesesuaian 80%. Meski demikian, jumlah sampel evaluasi yang hanya 20 data membuat hasil ini sebaiknya dipandang sebagai gambaran awal.

2. Clustering

Pengelompokan terhadap 516 unggahan menggunakan TF-IDF dan K-Means menghasilkan tiga cluster berdasarkan kemiripan teks.

Cluster	Jumlah Data	Persentase
0	365	70,7%
1	31	6,0%
2	120	23,3%

WordCloud Percakapan Dunia Kerja



Cluster 0 merupakan kelompok terbesar (70,7%), diikuti Cluster 2 (23,3%) dan Cluster 1 (6,0%). Kata dominan pada WordCloud membantu mengidentifikasi tema percakapan. Penentuan tema setiap cluster perlu didukung kata dominan atau contoh unggahan dari cluster tersebut.

3. Regresi

- Pada Analisis regresi linear dilakukan untuk memperkirakan jumlah *likes* (like_count) pada postingan. Berdasarkan eksplorasi awal terhadap karakteristik dataset yang mencakup 516 baris data bersih, nilai *like_count* memiliki rentang yang sangat ekstrem, yakni dari minimum 0 hingga maksimum 58.943 *likes* dengan rata rata ukuran mencapai 6.940, sementara *retweet_count* berada pada rentang 0–19.350 dan *reply_count* pada rentang 0–1.465.

- Dalam implementasinya, baik pada tahap eksperimen maupun saat diintegrasikan ke dalam aplikasi web Streamlit (app.py), pemodelan regresi menggunakan variabel interaksi metrik keterlibatan pengguna (*engagement*), yaitu jumlah balasan (reply_count) dan jumlah penyebaran ulang (retweet_count) terhadap 516 baris data valid (pembagian 80% data latih / 412 baris dan 20% data uji / 104 baris). Berdasarkan matriks korelasi (*heatmap*), variabel *reply* dan *retweet* terbukti memiliki tingkat keterkaitan yang jauh lebih kuat dan linear terhadap jumlah *likes* dibandingkan fitur teks biasa.
- Model regresi linear yang dihasilkan menunjukkan hubungan positif yang signifikan: setiap kenaikan jumlah *retweet* dan *reply* berkontribusi langsung terhadap peningkatan prediksi jumlah *likes*. Evaluasi model pada data uji menghasilkan nilai *Mean Absolute Error* (MAE) dan skor determinasi (R^2) yang mencerminkan performa model. Selain itu, aplikasi web Streamlit juga dilengkapi dengan **Formulir Estimasi Likes** interaktif yang secara otomatis menghitung prediksi jumlah *likes* ketika pengguna memasukkan angka *reply* dan *retweet* secara langsung.

D. Temuan dan keterbatasan.

Temuan : Analisis sentimen menunjukkan bahwa percakapan didominasi sentimen netral (50,4%), diikuti negatif (40,9%) dan positif (8,7%). Clustering membagi 516 data menjadi tiga kelompok, dengan Cluster 0 sebagai kelompok terbesar (70,7%). Pada analisis regresi, jumlah reply dan retweet digunakan sebagai prediktor jumlah likes karena memiliki keterkaitan yang lebih kuat dibandingkan fitur teks seperti word_count dan hashtag_count. Aplikasi Streamlit juga menyediakan formulir interaktif untuk memperkirakan jumlah likes berdasarkan kedua variabel tersebut.

Keterbatasan : Data hasil crawling belum tentu mewakili seluruh pandangan Gen Z dan masih berpotensi mengandung unggahan promosi yang kurang relevan. Selain itu, TF-IDF dan K-Means memiliki keterbatasan dalam memahami konteks percakapan, sedangkan performa regresi perlu dinilai berdasarkan nilai MAE dan (R^2) pada data uji. Rentang jumlah likes yang sangat lebar, dari 0 hingga 58.943, juga dapat memengaruhi ketepatan prediksi model.

E. Pembagian Kontribusi Anggota

Neshia Septiarifa 24051130001	Melakukan crawling data (kerja.csv & kerja2.csv), merging, pembersihan teks (cleaning), normalisasi kolom, dan filter relevansi topik, membantu membuat laporan.
Angger Sekarayu L.B. 24051130003	Mengembangkan modul clustering (TF-IDF & K-Means), evaluasi Silhouette Score, visualisasi PCA, serta analisis dominasi kata dan tema tiap cluster, membantu proses cleaning data, membuat tab clustering pada streamlit, membantu membuat laporan.
Bayu Arya Wijaya 24051130010	Membangun modul Regresi Linear di Colab, merancang aplikasi web Streamlit (app.py) [membantu Tab Data, clustering analisis], membuat Tab Regresi hingga mendapatkan output formulir dan grafik likes aktual vs prediksi , menyusun requirements.txt dan README.md, serta buat laporan.
Audi Ariz Q 24051130016	Mengembangkan analisis sentimen menggunakan IndoBERT, rekapitulasi distribusi, visualisasi grafik, pelabelan manual, penyusunan file evaluasi, penyusunan laporan, dan mendeploy sistem ke streamlit.io.

Link github : https://github.com/Bayustudent56/kelompok_2-_kerja

Link Deploy : https://kelompok2-kerja-l5dwqbh7fno9cahtblf7xe.streamlit.app/