LAPORAN PROYEK APLIKASI WEBSITE

KELOMPOK 2

Topik: Analisis Data Percakapan Pengguna X tentang Gaji dan Tantangan Gen Z dalam Memasuki Dunia Kerja

Dosen Pengampu: Akhsin Nurlayli, S.Pd., M.Eng.

Nama Anggota :

1. **NESHIA SEPTIARIFA (24051130001)**
2. **ANGGER SEKARAYU LANGGENG B (24051130003)**
3. **BAYU ARYA WIJAYA (24051130010)**
4. **AUDI ARIZ Q (24051130016)**

TEKNOLOGI INFORMASI

DEPARTEMEN PENDIDIKAN TEKNIK ELEKTRONIKA DAN INFORMATIKA

FAKULTAS TEKNIK

UNIVERSITAS NEGERI YOGYAKARTA

2026

A. Topik, Kata Kunci, Sumber, Periode, Serta Jumlah Data.

Topik : Gaji, upah minimum regional (UMR), pencarian kerja, dan tantangan memasuki dunia kerja
Kata Kunci : "gaji UMR", "lowongan kerja", dan "fresh graduate"
Sumber : Platform X (Twitter)
Periode : 21 Oktober 2014 - 12 Oktober 2026
Data awal : 650
Data akhir : 516

B. Pembersihan Data dan Metode

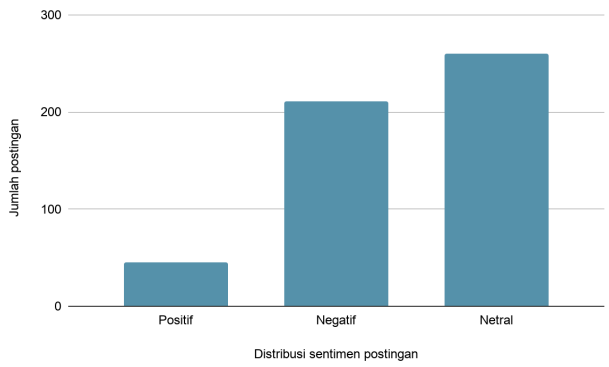
Pengumpulan data dilakukan menggunakan Tweet-Harvest melalui Google Colab dengan kata kunci gabungan “gaji UMR”, “lowongan kerja”, dan “fresh graduate” pada platform X dalam rentang waktu dari 21 Oktober 2014 hingga 12 Oktober 2026. Pengambilan data dilakukan sebanyak dua kali dengan batas masing-masing 1.000 dan 500 unggahan. Data yang diperoleh kemudian digabungkan dan melalui tahapan pembersihan sebagai berikut:

1. Penghapusan data duplikat, dengan menggabungkan hasil crawling dari dua file CSV dan menghapus unggahan yang memiliki ID atau isi teks yang sama untuk menghindari penghitungan data berulang.
2. Penghapusan data kosong dan pembersihan teks, dengan membersihkan teks unggahan melalui proses case folding, penghapusan URL, mention, hashtag, simbol, angka, stopwords, serta spasi berlebih. Hasil pembersihan disimpan dalam kolom Cleaned_Text.
3. Normalisasi data, dengan mengonversi tanggal unggahan ke format waktu UTC serta memastikan nilai metrik interaksi, seperti likes, retweet, reply, dan quote, memiliki nilai numerik dengan nilai kosong diisi nol.
4. Penyaringan bahasa dan seleksi relevansi, dengan mempertahankan unggahan berbahasa Indonesia berdasarkan kolom lang, kemudian menyeleksi unggahan yang relevan dengan topik gaji dan tantangan Gen Z dalam memasuki dunia kerja menggunakan daftar kata kunci terkait dunia kerja.
5. Penyimpanan hasil cleaning, dengan menyimpan data yang telah dibersihkan dan diseleksi ke dalam file cleaning_kerja_relevan.csv untuk digunakan pada tahap analisis selanjutnya.

C. Hasil Utama Sentimen, Clustering, dan Regresi.

1. Sentimen

Analisis sentimen terhadap 516 postingan menggunakan model IndoBERT menunjukkan bahwa sentimen netral mendominasi dengan 260 postingan (50,39%), diikuti sentimen negatif sebanyak 211 postingan (40,89%), dan sentimen positif sebanyak 45 postingan (8,72%).



Dominasi sentimen netral menandakan bahwa sebagian besar postingan bersifat informatif, seperti informasi lowongan kerja atau pertanyaan seputar upah, sedangkan sentimen negatif yang mencapai hampir 41% mencerminkan adanya keluhan publik terhadap besaran upah dan

kondisi dunia kerja. Sentimen positif hanya menempati porsi terkecil, sehingga apresiasi terhadap topik ini relatif jarang muncul.

Untuk mengukur kinerja model, hasil prediksi IndoBERT dibandingkan dengan pelabelan manual pada 20 sampel postingan.

Metrik Evaluasi	Jumlah Data	Persentase	Keterangan
Sesuai (Match)	16	80,0%	Prediksi sistem sama dengan label manual
Tidak Sesuai (Mismatch)	4	20,0%	Prediksi sistem berbeda dari label manual
Tidak Sesuai (Mismatch)	20	100,0%	Total data yang diuji pada file evaluasi

Hasilnya, 16 dari 20 postingan (80,0%) memiliki label yang sesuai, sedangkan 4 postingan (20,0%) tidak sesuai. Ketidaksesuaian umumnya terjadi pada kelas yang berdekatan, yaitu antara netral dengan positif atau negatif, karena batas antara teks netral dan teks beremosi ringan cukup samar, terutama pada bahasa media sosial yang informal dan penuh singkatan. Dengan demikian, IndoBERT dinilai cukup baik dalam mengklasifikasikan sentimen dengan tingkat kesesuaian 80%. Meski demikian, jumlah sampel evaluasi yang hanya 20 data membuat hasil ini sebaiknya dipandang sebagai gambaran awal.

2. Clustering

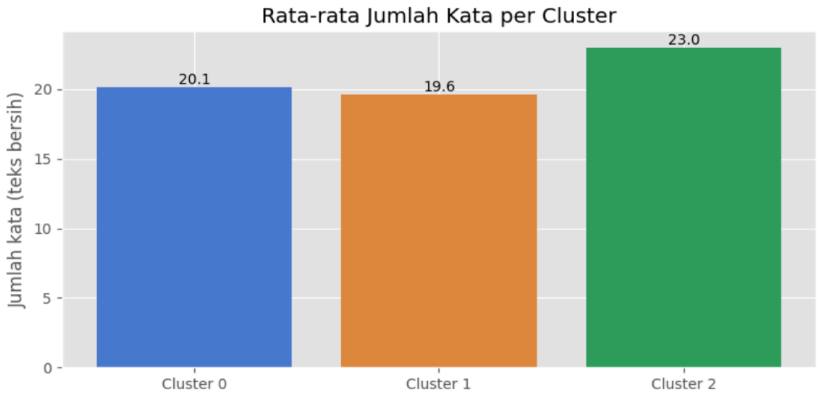
Pengelompokan terhadap 516 postingan menggunakan metode TF-IDF dan algoritma K-Means menghasilkan tiga cluster berdasarkan kemiripan representasi teks. Jumlah cluster ditetapkan tiga sesuai ketentuan tugas. Distribusi anggota, kata dominan, dan tema setiap cluster ditampilkan pada tabel dibawah.

Cluster	Jumlah Data	Persentase	Kata Dominan	Rata-rata panjang (rentang)	Tema
0	365	70,7%	gaji, umr, kerja, gaji umr, lowongan	20,1 kata (2–49)	Diskusi Gaji, UMR, dan Tantangan Mencari Kerja
1	31	6,0%	oktober, posisi, pt, lowongan, baca	19,6 kata (9–29)	Informasi Lowongan Kerja dan Rekrutmen
2	120	23,3%	fresh graduate, fresh, graduate, pengalaman, kerja	23,0 kata (4–40)	Tantangan Fresh Graduate dan Persyaratan Pengalaman

- Cluster 0 - Diskusi Gaji, UMR, dan Tantangan Mencari Kerja
  Cluster 0 adalah kelompok terbesar (365 postingan, 70,7%). Kata “gaji” muncul 343 kali dan “umr” 312 kali, sehingga kelompok ini didominasi pembahasan upah dan pencarian kerja. Isinya berupa keluhan dan opini pengguna, tetapi juga memuat kumpulan lowongan dan berita yang menyinggung gaji, sehingga cluster ini bersifat campuran dan bukan satu tema tunggal.
  Contoh postingan:

1) Berita seorang lulusan SMK di Jakarta yang kesulitan mendapat pekerjaan pertama karena banyak lowongan mensyaratkan pengalaman, meski sudah berkali-kali melamar.
2) “Kumpulan lowongan kerja (loker) minimal gaji UMR Jakarta. Bulan Agustus. A thread (will be updated regularly)…”
3) “buat perusahaan-perusahaan minimal kalo gaji dibawah UMR interviewnya gausah ribet sampe bercabang-cabang 10 tes…”

- Cluster 1 - Informasi Lowongan Kerja dan Rekrutmen
  Cluster 1 berisi 31 postingan (6,0%) dan merupakan kelompok dengan tema paling jelas, karena ketiga contohnya adalah iklan lowongan berformat seragam. Kata “lowongan” muncul 36 kali, “posisi” 25 kali, dan “PT” 22 kali, mencerminkan isi iklan yang menyebut perusahaan, posisi, dan periode pendaftaran.
  Contoh postingan:
  1) “Lowongan Kerja PT [nama perusahaan]. Posisi: Management Trainee 2027. Kualifikasi: S1/S2. Periode pendaftaran: 10–31 Oktober 2026…”
  2) “[LOWONGAN KERJA] Saatnya melangkah lebih jauh dalam kariermu! PT [nama perusahaan] lagi buka lowongan untuk posisi Production Engineer, Management Trainee (Produksi)…”
  3) “Lowongan Kerja PT [nama perusahaan] Oktober 2026. Penempatan: Seluruh Indonesia. Baca selengkapnya…”
- Cluster 2 - Tantangan Fresh Graduate dan Persyaratan Pengalaman
  Cluster 2 memuat 120 postingan (23,3%) dengan kata “fresh” (106 kali), “graduate” (105 kali), dan “pengalaman” (40 kali). Isinya beragam: curhat sulitnya fresh graduate mendapat kerja, berita upah awal fresh graduate, dan iklan lowongan yang menyebut fresh graduate. Tema “tantangan” paling kuat pada contoh kedua, sedangkan contoh lain lebih berkaitan dengan upah dan iklan.
  Contoh postingan:
  1) Berita kenaikan upah minimum di Malaysia, termasuk upah awal minimum bagi fresh graduate sebesar Rp 10,95 juta.
  2) “…ada beberapa fakta menyedihkan: job market sekarang jauh beda sama 2016, sekarang bahkan fresh graduate aja susah cari kerja…”
  3) “Mimpi Basah Para Pejuang Loker di Indonesia. Syarat: pendidikan min SMA/SMK/D3/S1 semua jurusan, fresh graduate boleh melamar… Gaji Rp 12.000.000…”



Gambar. Rata-rata panjang postingan per cluster.

- Perbedaan Isi Ketiga Cluster
  Cluster 0 berisi keluhan dan opini tentang gaji, UMR, dan sulitnya mencari kerja. Cluster 1 berisi iklan lowongan berformat seragam. Cluster 2 berfokus pada fresh graduate dan

persyaratan pengalaman. Kata gaji, umr, dan fresh graduate juga merupakan kata kunci pengumpulan data, sehingga dominasinya sebagian mencerminkan cara data dikumpulkan, bukan semata perbedaan topik.

- Tumpang Tindih dan Evaluasi

  Masih terdapat pembahasan yang tumpang tindih. Silhouette Score (cosine) hanya 0,0155, mendekati nol, yang berarti banyak postingan hampir sama dekatnya ke cluster lain dan batas antar cluster belum tegas. Sebanyak 69 dari 516 postingan (13,4%) hampir sama dekatnya ke dua pusat cluster (selisih kemiripan di bawah 0,05, indikator kasar yang ditetapkan sendiri, bukan standar baku). Kata dominan yang sama juga ditemukan pada ketiga pasangan cluster, terutama "lowongan" dan "lowongan kerja"; kata "kerja" dibagi Cluster 0 dan 2, sedangkan "pt" dibagi Cluster 1 dan 2. Tumpang tindih juga terlihat pada contoh: berita lulusan SMK yang terhambat syarat pengalaman (Cluster 0) sangat mirip dengan curhat fresh graduate di Cluster 2. Kumpulan lowongan berbasis UMR (Cluster 0) dan iklan "Mimpi Basah Para Pejuang Loker" (Cluster 2) sama-sama berbentuk informasi lowongan seperti isi Cluster 1. Dengan Silhouette Score yang sangat rendah, tema sebaiknya dipahami sebagai kecenderungan kasar, bukan pemisahan topik yang tegas, dan tetap perlu dibaca bersama isi postingan.

3. Regresi

- Pada Analisis regresi linear dilakukan untuk memperkirakan jumlah *likes* (like_count) pada postingan. Berdasarkan eksplorasi awal terhadap karakteristik dataset yang mencakup 516 baris data bersih, nilai *like_count* memiliki rentang yang sangat ekstrem, yakni dari minimum 0 hingga maksimum 58.943 *likes* dengan rata rata ukuran mencapai 6.940, sementara *retweet_count* berada pada rentang 0–19.350 dan *reply_count* pada rentang 0–1.465.
- Dalam implementasinya, baik pada tahap eksperimen maupun saat diintegrasikan ke dalam aplikasi web Streamlit (app.py), pemodelan regresi menggunakan variabel interaksi metrik keterlibatan pengguna (*engagement*), yaitu jumlah balasan (reply_count) dan jumlah penyebaran ulang (retweet_count) terhadap 516 baris data valid (pembagian 80% data latih / 412 baris dan 20% data uji / 104 baris). Berdasarkan matriks korelasi (*heatmap*), variabel *reply* dan *retweet* terbukti memiliki tingkat keterkaitan yang jauh lebih kuat dan linear terhadap jumlah *likes* dibandingkan fitur teks biasa.
- Model regresi linear yang dihasilkan menunjukkan hubungan positif yang signifikan: setiap kenaikan jumlah *retweet* dan *reply* berkontribusi langsung terhadap peningkatan prediksi jumlah *likes*. Evaluasi model pada data uji menghasilkan nilai *Mean Absolute Error* (MAE) dan skor determinasi (R^2) yang mencerminkan performa model. Selain itu, aplikasi web Streamlit juga dilengkapi dengan **Formulir Estimasi Likes** interaktif yang secara otomatis menghitung prediksi jumlah *likes* ketika pengguna memasukkan angka *reply* dan *retweet* secara langsung.

D. Temuan dan keterbatasan.

Temuan :

- Sentimen: dari 516 postingan, 260 netral (50,4%), 211 negatif (40,9%), dan 45 positif (8,7%). Postingan negatif sekitar 4,7 kali lebih banyak daripada positif, sehingga percakapan lebih banyak berisi informasi dan keluhan daripada apresiasi. Hasil klasifikasi IndoBERT sesuai dengan label manual pada 16 dari 20 sampel (80%), dan keempat ketidaksesuaian melibatkan kelas netral.
- Clustering: 516 postingan terbagi menjadi tiga kelompok: diskusi gaji dan UMR (Cluster 0, 365 postingan, 70,7%), informasi lowongan kerja (Cluster 1, 31 postingan, 6,0%), dan tantangan fresh graduate (Cluster 2, 120 postingan, 23,3%). Cluster 1 paling jelas temanya,

sedangkan Cluster 0 dan 2 saling tumpang tindih (Silhouette Score 0,0155; 13,4% postingan ambigu).

- Regresi: retweet (r = 0,906) dan reply (r = 0,654) berkorelasi kuat dengan likes, sedangkan word_count (r = 0,003) dan hashtag_count (r = −0,066) hampir tidak berkorelasi. Model Likes = 176,18 + 15,81 × reply + 2,78 × retweet menghasilkan R^2 0,8788 dan MAE 912,40 pada 104 data uji. Likes karenanya lebih terkait dengan interaksi pengguna daripada dengan panjang atau hashtag teks.

Keterbatasan :

- Data: data diambil dengan tiga kata kunci tertentu dari satu platform dan periode, serta tanpa informasi usia penulis, sehingga hasil tidak dapat diklaim mewakili pandangan Gen Z. Data juga masih memuat iklan lowongan dan unggahan promosi yang kemungkinan menaikkan porsi sentimen netral dan membentuk Cluster 1.
- Sentimen: klasifikasi memakai model IndoBERT umum tanpa penyesuaian pada data ini, dan validasi manual hanya 20 sampel, sehingga tingkat kesesuaian 80% hanya perkiraan kasar. Bahasa informal dan sarkasme sulit dikenali.
- Clustering: TF-IDF dan K-Means mengelompokkan berdasarkan kemiripan kata, bukan makna. Jumlah cluster ditetapkan tiga, kata kunci pengumpulan data memengaruhi pembentukan cluster, dan Silhouette Score yang sangat rendah menunjukkan batas antar cluster belum tegas.
- Regresi: R^2 tinggi tetapi MAE 912,40 besar bagi postingan berlikes kecil, karena sebaran likes sangat timpang (0 sampai 58.943) dan sedikit postingan viral memengaruhi model. Contohnya, postingan dengan 41 likes diprediksi 318,48 likes. Reply dan retweet saling berkorelasi (r = 0,496), model hanya memakai dua prediktor, dan hasilnya menunjukkan keterkaitan, bukan sebab-akibat.

E. Pembagian Kontribusi Anggota

Neshia Septiarifa 24051130001	Melakukan crawling data (kerja.csv & kerja2.csv), merging, pembersihan teks (cleaning), normalisasi kolom, dan filter relevansi topik, membantu membuat laporan.
Angger Sekarayu L.B. 24051130003	Mengembangkan modul clustering (TF-IDF & K-Means), evaluasi Silhouette Score, visualisasi PCA, serta analisis dominasi kata dan tema tiap cluster, perhitungan kata (wordcount) pada postingan, membantu proses cleaning data, membuat tab clustering pada streamlit, membantu membuat laporan.
Bayu Arya Wijaya 24051130010	Membangun modul Regresi Linear di Colab, merancang aplikasi web Streamlit (app.py) [membantu Tab Data dan analisis], membuat Tab Regresi hingga mendapatkan output formulir dan grafik likes aktual vs prediksi , menyusun requirements.txt dan README.md, serta buat laporan.
Audi Ariz Q 24051130016	Mengembangkan analisis sentimen menggunakan IndoBERT, rekapitulasi distribusi, visualisasi grafik, pelabelan manual, penyusunan file evaluasi, penyusunan laporan, dan mendeploy sistem ke streamlit.io.

F. Tautan terkait:

Github : https://github.com/Bayustudent56/kelompok_2-_kerja

Deploy : https://kelompok2-kerja-l5dwqbh7fno9cahtblf7xe.streamlit.app/